



UNIVERSIDAD
COMPLUTENSE
MADRID

TeaSuitability

**Sistema inteligente de evaluación de idoneidad
geográfica para el cultivo del té de calidad**

Trabajo Fin de Máster

Máster en Big Data, Data Science e Inteligencia
Artificial

VALERIA SULLIOTTI
SEPTIEMBRE, 2026

Contenido

1. Resumen ejecutivo.....	2
2. Contexto y justificación del proyecto.....	2
2.1. El problema de negocio	2
2.2. El caso de estudio: Costa Rica	3
3. Objetivos	3
4. Metodología y arquitectura de la solución	3
4.1. Arquitectura y flujo de trabajo del sistema	4
4.2. Resultados generados por el sistema.....	5
5. Origen y construcción de los datos	6
5.1. Fuentes utilizadas	6
5.2. Diseño del conjunto de datos.....	6
5.3. Criterios de selección de las variables.....	6
6. Análisis exploratorio de los datos	7
7. Modelización	10
7.1. El desafío de la validación en datos geográficos.....	10
7.2. Algoritmos evaluados	10
8. Evaluación y resultados	11
8.1. Modelo final: combinación de algoritmos.....	11
9. Interpretabilidad del modelo.....	12
10. Productivización: aplicación y mapa de idoneidad	12
10.1. Aplicación web	12
10.2. Mapa de idoneidad a escala de país	13
11. Casos de aplicación	14
11.1. Turrialba, Costa Rica: idoneidad alta (89,5 %)	15
11.2. Assam, India: idoneidad alta (86,8 %)	15
11.3. Guanacaste seco, Costa Rica: no apta (3,7 %).....	16
12. Evolución del modelo y decisiones metodológicas.....	16
12.1. Primera iteración: solo variables climáticas	16
12.2. Segunda iteración: incorporación del suelo	17
12.3. Tercera iteración: revisión de las variables bioclimáticas	17
12.4. Cuarta iteración: exclusión de la isothermalidad	17
12.5. Configuración final y síntesis del proceso.....	18
13. Limitaciones del estudio.....	18
14. Conclusiones.....	19
15. Líneas futuras de trabajo	19
16. Bibliografía y fuentes de datos.....	20
17. Anexos: código y repositorio	21

1. Resumen ejecutivo

El té es la segunda bebida más popular del mundo, justo después del agua, y se cultiva en más de cincuenta países, abarcando alrededor de 5,27 millones de hectáreas (Bania, y otros, 2025). Sin embargo, la decisión sobre dónde plantar té sigue siendo, en gran medida, un proceso que depende de la experiencia local y de un enfoque de prueba y error. Dado que una plantación de té tarda entre tres y cinco años en comenzar a producir, un error en la elección del lugar puede significar años de inversión desperdiciada.

Este trabajo presenta TeaSuitability, un sistema que aborda una pregunta de negocio muy específica: **¿es un lugar determinado del planeta adecuado para cultivar té de calidad, y por qué?** El sistema aprende de las condiciones ambientales de cientos de plantaciones reales documentadas en todo el mundo y tiene la capacidad de evaluar nuevas ubicaciones, explicando de manera clara qué factores favorecen o limitan el cultivo.

Para lograr esto, se ha creado un conjunto de datos propio que incluye 1.363 ubicaciones, combinando tres fuentes públicas independientes: los registros globales de la planta de té (**GBIF**), las variables climáticas globales (**WorldClim**) y las propiedades del suelo (**SoilGrids**). Se han entrenado y comparado cuatro algoritmos de aprendizaje automático sobre este conjunto, que finalmente se han integrado en un modelo conjunto, validando su capacidad para predecir en territorios que nunca había analizado antes.

Los resultados son impresionantes: el sistema logra un área bajo la curva ROC de 0,95 en una validación geográfica estricta, lo que significa que puede distinguir correctamente entre zonas aptas y no aptas, incluso en regiones del mundo que no formaron parte de su entrenamiento. En el caso de estudio, identifica Turrialba, Costa Rica, como una zona de alta idoneidad (89,5 %), reconoce Assam, India (la mayor región productora de té del mundo) con un 86,8 %, y descarta correctamente la zona seca de Guanacaste, Costa Rica, con un 3,7 %.

El proyecto termina con dos entregables muy prácticos: una aplicación web que permite a cualquier persona ingresar las condiciones de un lugar y recibir una evaluación acompañada de una explicación detallada, y un mapa de idoneidad de Costa Rica que destaca las áreas con mayor potencial para el cultivo en el territorio.

2. Contexto y justificación del proyecto

2.1. El problema de negocio

La producción global de té supera los 29 millones de toneladas al año, generando alrededor de 17.000 millones de dólares en ingresos, además de otros 9.500 millones provenientes de exportaciones. Más del 60 % de esta producción está en manos de pequeños agricultores (Bania, y otros, 2025), quienes enfrentan graves consecuencias económicas si toman decisiones erróneas sobre dónde plantar.

El té es un cultivo que demanda mucho. Necesita temperaturas templadas, entre 18 y 25 °C, y su crecimiento se ve afectado si las temperaturas bajan de 13 °C o suben de 30 °C (Carr, 1972; de Costa et al., 2007). También requiere una buena cantidad de lluvia, más de 1.200 mm al año, y, muy importante, suelos ácidos con un pH entre 4,5 y 5,6 (Hajiboland, 2017). Estas condiciones han limitado históricamente su cultivo a unas pocas regiones en Asia y África (Hajiboland, 2017).

A esto se le suma un sentido de urgencia: el cambio climático está alterando el mapa de las áreas cultivables. Estudios recientes indican que, para 2050, países como Argentina, Malawi o Tanzania podrían ver una reducción de entre el 60 % y el 78 % de su superficie altamente apta, mientras que naciones como Irán, Ruanda, Tailandia o Turquía podrían experimentar

un aumento de entre el 11 % y el 27 (Bania, y otros, 2025). Contar con herramientas que evalúen la idoneidad de manera objetiva y reproducible ya no es solo un ejercicio académico, sino que se ha convertido en una necesidad crucial para la planificación agrícola.

2.2. El caso de estudio: Costa Rica

Aunque Costa Rica no es conocido como un país productor de té, tiene características que hacen que valga la pena preguntarse: suelos volcánicos ácidos, abundante lluvia, altitudes medias y una sólida industria cafetalera cuyos requerimientos agronómicos coinciden con los del té. Este estudio se enfoca en Turrialba, en la provincia de Cartago, una zona montañosa con una rica tradición agrícola y de investigación.

Además, la viabilidad del cultivo en América Latina está bien documentada. La región productora de té en Argentina, ubicada en Misiones y Corrientes, cultiva té en un clima subtropical húmedo, con precipitaciones que oscilan entre 1,800 y 2,200 mm al año, altitudes de 150 a 550 metros y suelos con un pH de entre 5.2 y 5.5 (Prat Kricun, Belingheri, & Kuzdra, 2020). Estos valores son bastante similares a los que se encuentran en las zonas montañosas de Costa Rica, lo que sugiere que la pregunta planteada no es simplemente una hipótesis sin fundamento.

Por lo tanto, la cuestión que este proyecto busca responder no es solo técnica, sino también económica: ¿podría Costa Rica (y en particular Turrialba) ser un lugar adecuado para cultivar té de calidad, y cuáles serían las áreas del país más propicias para ello?

3. Objetivos

El objetivo principal es crear un sistema que pueda evaluar de manera automática y comprensible la idoneidad de cualquier lugar para cultivar té de calidad. A partir de esto, se desprenden cinco objetivos específicos:

- Desarrollar un conjunto de datos propio utilizando fuentes públicas independientes, sin depender de datasets ya existentes ni de datos sintéticos.
- Comparar diferentes técnicas de aprendizaje automático, explicando sus ventajas y desventajas, y evaluarlas con un enfoque honesto que se ajuste a la naturaleza geográfica de los datos.
- Convertir los resultados del modelo en categorías que sean fáciles de entender para un usuario sin conocimientos técnicos (idoneidad alta, media, baja o no apta).
- Ofrecer explicaciones para cada predicción individual, señalando qué factores ambientales influyen en ellas.
- Implementar el modelo a través de una aplicación funcional y un mapa de idoneidad a nivel nacional.

4. Metodología y arquitectura de la solución

El proyecto se basa en la metodología CRISP-DM, que es un estándar en el ámbito de la analítica avanzada. Esta metodología organiza el trabajo en fases sucesivas que incluyen la comprensión del negocio, la comprensión y preparación de los datos, la modelización, la evaluación y el despliegue. La solución ha sido desarrollada en Python 3.12, utilizando scikit-learn como la herramienta principal para la modelización, y se ha estructurado en módulos que son independientes y fáciles de reproducir.

Módulo	Fase CRISP-DM	Función
A.1	Preparación de datos	Construcción del conjunto de datos geoespacial
A.2	Comprensión de datos	Análisis exploratorio, reducción de dimensión y agrupación
B.1	Modelización	Preparación y diseño de la validación geográfica
B.2	Modelización	Entrenamiento y comparación de cuatro algoritmos
B.3	Modelización	Modelo conjunto y traducción a bandas de idoneidad
C.1	Evaluación	Interpretabilidad e informe en lenguaje natural
C.2	Despliegue	Aplicación web interactiva
D	Despliegue	Mapa de idoneidad a escala de país

Tabla 1. Estructura modular del proyecto y correspondencia con las fases de CRISP-DM.

4.1. Arquitectura y flujo de trabajo del sistema

El sistema ha sido concebido como una serie de módulos interconectados, donde cada uno utiliza lo que genera el anterior y produce un resultado concreto para el siguiente. Esta estructura se basa en un enfoque práctico: facilita la ejecución, revisión o modificación de cualquier fase sin tener que repetir todo el proceso, lo cual es especialmente útil cuando una etapa (como el muestreo de las propiedades del suelo) demanda un tiempo de cómputo considerable.




Ilustración 1. Arquitectura del sistema: fuentes de datos, módulos de procesamiento, archivos generados y entregables finales.

El flujo se organiza en cuatro niveles. En el primero, encontramos las tres fuentes abiertas, que se consultan automáticamente a través de sus respectivas interfaces de acceso. El módulo A.1 se encarga de integrarlas: toma las coordenadas de presencia de GBIF, genera las pseudo-ausencias y consulta el valor de cada variable ambiental en todas esas ubicaciones, creando así la tabla maestra del proyecto.

El segundo nivel se dedica al análisis exploratorio (A.2), que no transforma los datos, sino que los caracteriza y los enriquece con las componentes principales y las agrupaciones obtenidas. En el tercer nivel, se agrupan los tres módulos de modelización: B.1 define cómo se evaluará el modelo, B.2 compara las alternativas disponibles y B.3 construye y serializa el modelo final.

El cuarto nivel está compuesto por los entregables, que utilizan un mismo modelo entrenado para diferentes propósitos: explicar una predicción específica (C.1), permitir la consulta interactiva de cualquier ubicación (C.2) y evaluar sistemáticamente un territorio completo (D).

La línea discontinua en el diagrama representa la retroalimentación del proceso. Los resultados obtenidos en las fases de evaluación e interpretabilidad llevaron a revisiones sucesivas de la selección de variables, lo que obligó a reejecutar la cadena desde su inicio. Este ciclo, lejos de ser un inconveniente, es el mecanismo que permitió al sistema perfeccionarse; su trayectoria se detalla en el apartado 12.

4.2. Resultados generados por el sistema

Los módulos generan resultados que se pueden verificar, lo que facilita saber en qué etapa está el proceso y reanudarlo sin confusiones.

Módulo	Resultado generado	Utilidad
A.1	dataset_master.csv	Tabla maestra: 1.363 ubicaciones con sus 7 variables
A.2	dataset_master_enriquecido.csv y figuras del análisis	Caracterización del conjunto y detección de redundancias
B.1	Conjuntos de entrenamiento y bloques geográficos	Esquema de validación honesta
B.2	Tabla comparativa de los cuatro algoritmos	Justificación de la técnica elegida
B.3	modelo_teachability_real.pkl	Modelo listo para usar sin reentrenar
C.1	Contribuciones SHAP e informe en texto	Explicación de cada predicción
C.2	Aplicación web operativa	Consulta interactiva por parte del usuario final
D	mapa_idoneidad_costarica.csv y mapa cartográfico	Identificación de las zonas de mayor potencial

Tabla 2. Resultados generados por cada módulo del sistema.

5. Origen y construcción de los datos

5.1. Fuentes utilizadas

No hay un conjunto de datos público que vincule directamente las ubicaciones con su idoneidad para el cultivo del té. Por lo tanto, el primer desafío del proyecto fue crear uno. Se combinaron tres fuentes abiertas, todas accesibles y sin restricciones de uso:

- GBIF (Global Biodiversity Information Facility): la mayor base de datos mundial sobre registros de biodiversidad. De aquí se extrajeron las coordenadas donde se ha documentado la presencia de *Camellia sinensis* (L.) O. Kuntze, la planta del té. Esta misma fuente fue utilizada por Bania et al. (2025) para desarrollar su modelo global.
- WorldClim 2.1 (Fick & Hijmans, 2017): se han identificado diecinueve variables bioclimáticas globales, las cuales se derivan de series históricas de estaciones meteorológicas y tienen una resolución de 5 minutos de arco, lo que equivale a unos 9 km. Estas variables son las capas ambientales más utilizadas en la modelización de la distribución de especies. De hecho, más del ochenta y siete por ciento de los estudios revisados sobre organismos terrestres emplea al menos una de estas variables. En resumen, estas variables capturan el clima a través de indicadores que son biológicamente significativos para el desarrollo de las plantas.
- SoilGrids (Poggio, y otros, 2021): propiedades del suelo a nivel global estimadas mediante técnicas de aprendizaje automático. De esta fuente se obtuvo el pH, un factor determinante para el cultivo del té.

El acceso a SoilGrids presentó un obstáculo inesperado: su interfaz de consulta estuvo temporalmente fuera de servicio durante el desarrollo. Para solucionarlo, se accedió directamente a sus archivos cartográficos, lo que requirió transformar las coordenadas al sistema de proyección específico de esta fuente. Esta situación, que refleja un entorno real de trabajo con datos, se documenta por su valor metodológico.

5.2. Diseño del conjunto de datos

El problema que estamos enfrentando tiene una característica bastante interesante: sabemos dónde hay té, pero no tenemos un registro claro de los lugares donde definitivamente no lo hay. Esto se conoce en el ámbito de la modelización de distribución de especies como un problema de «solo presencias» (Elith & Leathwick, 2009).

La solución que hemos adoptado, que es bastante común en este tipo de estudios, consiste en crear pseudo-ausencias. Estas son ubicaciones elegidas al azar dentro del área de estudio, que están lo suficientemente alejadas de cualquier presencia conocida y que asumimos como no aptas. Barbet-Massin et al. (2012) sugieren que, para los métodos de clasificación, se generen un número de pseudo-ausencias igual al de las presencias y que se aplique una distancia mínima de exclusión, criterios que hemos seguido en este trabajo. Así, el problema se plantea como una clasificación binaria (apto / no apto), y la salida es una probabilidad continua, a partir de la cual se derivan categorías que son más fáciles de interpretar. Este enfoque evita la necesidad de crear etiquetas intermedias que no tendrían un respaldo empírico.

El conjunto final incluye 1.363 ubicaciones, equilibradas entre las presencias documentadas y las pseudo-ausencias, distribuidas por Asia, África, América y Oceanía, abarcando un rango de longitudes de -84° a 176° y de latitudes de -43° a 51° .

5.3. Criterios de selección de las variables

WorldClim ofrece un total de diecinueve variables bioclimáticas, además de la elevación y las diversas propiedades del suelo que proporciona SoilGrids. Incluir todas estas variables no

solo es innecesario, sino que puede ser contraproducente: las variables que están muy correlacionadas entre sí pueden generar redundancia y afectar la estimación de la importancia de cada factor, un problema que se ha documentado ampliamente en la modelización ecológica. De hecho, Bania et al. (2025) comienzan con un conjunto de cincuenta y una variables y terminan descartando treinta y una debido a la colinealidad antes de proceder con el modelado.

- Relevancia agronómica comprobada. Cada variable tenía que alinearse con un requerimiento documentado del cultivo en la literatura especializada (Hajiboland, 2017) (Bania, y otros, 2025).
- Adecuación al contexto del caso de estudio. Se priorizaron indicadores informativos en climas tropicales isohídricos como el de Costa Rica, donde la variación térmica entre estaciones es mínima y el ritmo predominante es la alternancia entre la estación seca y la lluviosa.
- Interpretabilidad para el usuario final. Dado que el sistema debía ser capaz de explicar sus decisiones a personas sin formación técnica, se descartaron indicadores que fueran difíciles de traducir en la práctica.

El resultado es un conjunto compacto de siete variables que abordan los tres ejes que determinan la idoneidad del té: régimen térmico, disponibilidad y distribución del agua, y condiciones del terreno y del suelo.

Variable	Qué mide	Relevancia para el té
Temperatura media anual	Promedio térmico del año	Óptimo: 18–25 °C
Rango diario medio	Diferencia entre la máxima diurna y la mínima nocturna	Noches frescas mejoran la calidad
Precipitación anual	Lluvia total del año	Óptimo: 1.500–3.000 mm
Estacionalidad de precipitación	Variabilidad de la lluvia entre estaciones	Se prefiere lluvia repartida
Precipitación del trimestre seco	Lluvia acumulada en los tres meses más secos	Indica estrés hídrico
Elevación	Altitud sobre el nivel del mar	Cultivo hasta ~2.200 m
pH del suelo	Acidez o alcalinidad del suelo	Óptimo: 4,5–5,5 (ácido)

Tabla 3. Variables del modelo y su justificación agronómica.

6. Análisis exploratorio de los datos

Antes de comenzar con el modelado, se llevó a cabo un análisis de la estructura del conjunto. Las distribuciones de las variables son coherentes con lo que se esperaba: la temperatura media se sitúa entre 15 y 25 °C, el pH del suelo tiene una moda clara alrededor de 5,5 (que es el rango ácido ideal para el té) y la precipitación presenta una gran variabilidad, lo que refleja la diversidad de climas que se han considerado.




Ilustración 2. Distribución de las siete variables ambientales del conjunto de datos.

El análisis de correlaciones nos muestra relaciones que tienen sentido físico y respaldan la calidad de los datos. Por ejemplo, se destaca una correlación negativa entre el pH del suelo y la precipitación anual ($-0,79$): cuando llueve mucho, las bases del suelo se lavan y se vuelve más ácido, lo que explica por qué las áreas más húmedas suelen tener suelos más ácidos, ideales para el cultivo del té. También es sugestivo la relación inversa entre el rango de temperatura diaria y la precipitación ($-0,76$): la nubosidad en las zonas lluviosas reduce la variación de temperatura entre el día y la noche.




Ilustración 3. Matriz de correlación entre las variables ambientales.

Se llevó a cabo un análisis de componentes principales para evaluar si había redundancia en el conjunto de datos. Se necesitan cuatro componentes para explicar el 91 % de la variabilidad total, lo que sugiere que las variables ofrecen información complementaria y no se repiten: el conjunto es compacto y está bien estructurado.




Ilustración 4. Varianza explicada acumulada por el análisis de componentes principales.

Al proyectar los datos en las dos primeras componentes, se observa que las áreas donde se cultiva té (en verde) ocupan una región distinta en el espacio ambiental, aunque hay cierto solapamiento con las pseudo-ausencias. Este solapamiento es esperado y, de hecho, resalta la necesidad de un modelo: la separación no es sencilla y requiere combinar varias variables al mismo tiempo.




Ilustración 5. Proyección de las ubicaciones sobre las dos primeras componentes principales.

Por último, se aplicaron técnicas de agrupación no supervisada para identificar perfiles ambientales. El método del codo y el coeficiente de silueta sugieren que hay entre dos y tres grupos, que corresponden a perfiles climáticos diferenciados (tropical húmedo, templado y seco). Este análisis confirma que el conjunto refleja la diversidad ambiental que se esperaba.




Ilustración 6. Selección del número de grupos mediante el método del codo y el coeficiente de silueta.

7. Modelización

7.1. El desafío de la validación en datos geográficos

Un aspecto clave de este trabajo, y probablemente su mayor contribución metodológica, es la forma en que se evalúa el modelo. En el ámbito de los datos geográficos, dos lugares cercanos suelen tener condiciones muy parecidas. Si al dividir los datos en conjuntos de entrenamiento y prueba, un punto termina en un grupo y su vecino inmediato en otro, el modelo puede parecer que tiene un buen rendimiento, pero en realidad solo está reconociendo información que ya ha procesado. Este fenómeno, conocido como autocorrelación espacial, puede llevar a métricas que son artificialmente optimistas (Roberts, y otros, 2017). El problema es doble: Beck et al. (2014) demostraron que la pérdida de calidad que resulta de agrupar espacialmente los registros pasa desapercibida con las métricas de evaluación tradicionales.

Para evitar esto, se implementó una validación cruzada espacial por bloques, tal como sugieren Roberts et al. (2017) para datos con estructura espacial: el territorio se divide en cinco bloques geográficos, y el modelo se entrena con algunos de ellos y se evalúa prediciendo en otros que nunca ha visto. Se verificó que los cinco bloques contienen presencia de té, lo cual es esencial para que la validación tenga sentido. Este enfoque de evaluación es mucho más riguroso, pero refleja mejor el uso real del sistema: predecir en áreas nuevas.

7.2. Algoritmos evaluados

Se entrenaron y compararon cuatro algoritmos diferentes para asegurarnos de que nuestra elección final fuera bien fundamentada y no dependiera de una sola técnica:

- Random Forest: un conjunto de árboles de decisión que votan al mismo tiempo. Es robusto y menos sensible a los valores extremos, aunque puede ser un poco menos preciso que las técnicas de refuerzo progresivo.
- XGBoost y LightGBM: estos algoritmos construyen árboles de manera secuencial, corrigiendo los errores del árbol anterior. Suelen ofrecer la mejor precisión en datos tabulares, aunque esto puede aumentar el riesgo de sobreajuste.
- SVM o máquina de vectores de soporte: este método busca la frontera que mejor separa las dos clases, maximizando el margen. Es importante estandarizar las variables antes de usarlo, así que lo incluimos en una secuencia de procesamiento que asegura que el escalado se aprenda solo con los datos de entrenamiento.

Todos los algoritmos se configuraron con ponderación de clases para equilibrar la presencia y ausencia de datos, evitando que el modelo se limitara a predecir siempre la clase mayoritaria.

8. Evaluación y resultados

La comparación se llevó a cabo utilizando dos enfoques complementarios: una división clásica de los datos (que puedes ver en las columnas de la izquierda) y la validación cruzada espacial (que se encuentra en las dos últimas columnas). Los resultados que obtuvimos son los siguientes:

```
Evaluando Random Forest ...
Evaluando XGBoost ...
Evaluando SVM ...
Evaluando LightGBM ...
```

Modelo	Accuracy	Precision	Recall	F1	ROC-AUC	F1_espacial	AUC_espacial
SVM	0.928	0.948	0.927	0.937	0.987	0.807	0.953
Random Forest	0.955	0.966	0.957	0.961	0.989	0.773	0.951
LightGBM	0.950	0.961	0.953	0.957	0.981	0.758	0.946
XGBoost	0.950	0.969	0.944	0.957	0.981	0.733	0.925

Ilustración 7. Comparativa de los cuatro algoritmos evaluados.

Al observar esta tabla, se pueden sacar conclusiones interesantes. **Todos los modelos logran superar el 0,93 de exactitud en la evaluación clásica, pero su rendimiento se reduce a un rango de entre 0,73 y 0,81 cuando los validamos geográficamente.** Esta diferencia no es un fallo; de hecho, es precisamente el tipo de sesgo que la validación espacial puede identificar, algo que una evaluación convencional podría haber pasado por alto.

Para poner estas cifras en perspectiva, los estudios sobre la idoneidad del té han reportado resultados similares: Jayasinghe y Kumar (2020) encontraron un área bajo la curva media de 0,92 para Sri Lanka. Sin embargo, es importante señalar que esos estudios utilizaron validación aleatoria, mientras que el valor que hemos alcanzado aquí proviene de predicciones realizadas sobre bloques geográficos que no se habían visto antes, lo que representa un desafío mucho mayor.

El segundo hallazgo es que el orden de los modelos varía según el método de evaluación. Random Forest se lleva la mejor puntuación en la evaluación clásica (0,955), pero es el SVM el que se desempeña mejor al generalizar en territorios nuevos (con un F1 espacial de 0,807 y un área bajo la curva ROC de 0,953). Dado que el objetivo de nuestro sistema es evaluar ubicaciones que no ha encontrado antes, la decisión se basó en el criterio espacial.

Mejor modelo por generalización espacial: SVM

Lectura: el holdout da métricas altas (~0.95 F1) pero optimistas por autocorrelación espacial; la validación espacial (F1 ~0.64-0.78) refleja el rendimiento real en territorios no vistos.

Ilustración 8. Selección del modelo según su capacidad de generalización geográfica.

8.1. Modelo final: combinación de algoritmos

Esta decisión de comparar diferentes técnicas surge de una limitación que se ha identificado en la literatura previa sobre el té: los estudios anteriores han tendido a enfocarse en un solo modelo para predecir la idoneidad del hábitat, basándose principalmente en variables bioclimáticas y dejando de lado los parámetros del suelo (Bania et al., 2025). Este trabajo se propone abordar ambas carencias.

En lugar de optar por un único algoritmo, el modelo final combina tres de ellos a través de un método de apilamiento o stacking: Random Forest, SVM y LightGBM funcionan como modelos base, mientras que una regresión logística se encarga de ponderar sus opiniones. Este enfoque de utilizar conjuntos de modelos también es el que Bania et al. (2025) han adoptado en su estudio más reciente sobre la idoneidad del té. Así, se aprovechan las fortalezas de cada técnica y se compensan sus debilidades individuales. XGBoost se dejó fuera de la versión final debido a un problema de compatibilidad en el entorno de despliegue, pero esto no afectó significativamente el rendimiento.

La salida del modelo es una probabilidad continua de idoneidad que se traduce en cuatro categorías interpretables mediante umbrales en los cuartiles: no apta (por debajo de 0,25), baja (0,25–0,50), media (0,50–0,75) y alta (por encima de 0,75). Esta conversión es lo que hace que el resultado sea accesible y comprensible, incluso para quienes no tienen conocimientos técnicos.

9. Interpretabilidad del modelo

Un modelo que acierta pero no explica el porqué de sus decisiones difícilmente genera confianza en quienes deben tomar decisiones. Por eso, se ha añadido una capa de explicabilidad basada en los valores SHAP, una técnica que se apoya en los valores de Shapley de la teoría de juegos, distribuyendo de manera justa la contribución de cada variable a cada predicción individual.

El sistema no solo se limita a dar un veredicto: también muestra cuánto influye cada factor en la aptitud (contribución positiva) o en su contra (contribución negativa), y genera automáticamente un informe redactado en un lenguaje claro y accesible. Este informe es el que traduce el resultado técnico a un lenguaje más cercano al mundo de los negocios.

10. Productivización: aplicación y mapa de idoneidad

10.1. Aplicación web

El modelo que hemos entrenado ahora está disponible en una aplicación web creada con Streamlit. Los usuarios pueden ingresar las condiciones ambientales de un lugar utilizando controles deslizantes, cada uno con una guía sobre el rango óptimo según lo que dice la literatura. De esta manera, obtienen al instante la probabilidad de idoneidad, la banda correspondiente, un desglose gráfico de los factores clave y un informe explicativo.

Condiciones del lugar

Rangos óptimos según la literatura agronómica del té.

Temperatura media anual (°C)

0.00 35.00

20.00

Rango diurno medio (°C)

3.00 20.00

10.00

Precipitación anual (mm)

500 5000

2000

Estacionalidad de precipitación

5.00 185.00

50.00

Precipitación del trimestre seco (mm)

0 900

200

Elevación (m)

0 3000

900

pH del suelo (ácido = mejor para el té)

3.50 8.50

5.00

Evaluar idoneidad



TeaSuitability

Evaluator de idoneidad geográfica para el cultivo de té de calidad (modelo entrenado con datos reales de GBIF, WorldClim y SoilGrids).

Ajusta las condiciones en la barra lateral y pulsa 'Evaluar idoneidad'.

Ilustración 9. Interfaz de la aplicación TeaSuitability.

Este componente hace realidad el objetivo de llevar la productividad a otro nivel: el modelo ya no es solo un resultado de laboratorio, sino que se transforma en una herramienta que permite ingresar nuevos valores y obtener una predicción que realmente se puede utilizar.

10.2. Mapa de idoneidad a escala de país

El segundo componente da un giro a la pregunta. En vez de centrarse en un solo lugar, se explora todo un territorio de manera sistemática para identificar las mejores áreas para cultivar. Para lograr esto, se crea una malla de puntos separados por aproximadamente 5,5 km que abarca toda Costa Rica, se analizan las condiciones ambientales reales y se predice la idoneidad de cada punto. El resultado es un total de 4.690 evaluaciones que forman el mapa que se presenta a continuación.




Ilustración 10. Mapa de idoneidad para el cultivo de té en Costa Rica.

El mapa es claro y agronómicamente consistente. La franja verde se extiende a lo largo de la Cordillera Volcánica Central y la Cordillera de Talamanca, que es precisamente la zona cafetalera de montaña del país, donde los requisitos se alinean con los del té. En contraste, la península de Guanacaste (noroeste) se muestra en rojo, lo que refleja su naturaleza de bosque seco tropical, al igual que las áreas costeras bajas, que son demasiado cálidas.

Es importante destacar un detalle significativo: el sistema no recibió información previa sobre la agricultura costarricense. Identificó estas áreas de manera independiente, basándose únicamente en las condiciones ambientales aprendidas de plantaciones de té en todo el mundo. Esta coincidencia con la realidad agrícola del país valida de manera independiente el modelo.

Las diez ubicaciones mejor valoradas se agrupan en el Valle Central y las laderas de los volcanes, con temperaturas que oscilan entre 17,4 y 21,0 °C, precipitaciones de 2.184 a 3.224 mm y un pH del suelo de 5,2 a 5,5: justo el perfil que la literatura agronómica considera óptimo.

11. Casos de aplicación

Para evaluar el comportamiento del sistema, se seleccionaron tres ubicaciones que contrastan entre sí de manera deliberada.

11.1. Turrialba, Costa Rica: idoneidad alta (89,5 %)



TeaSuitability

Evaluador de idoneidad geográfica para el cultivo de té de calidad (modelo entrenado con datos reales de GBIF, WorldClim y SoilGrids).

Probabilidad de idoneidad

89.5%

Banda de idoneidad

Alta

¿Por qué este resultado?




Ilustración 11. Evaluación de Turrialba y desglose de factores.

En este caso de estudio, la idoneidad es alta. El factor más influyente es el pH del suelo (peso 0,110), seguido por el rango de temperatura diurna y la cantidad de precipitación. La conclusión es clara: los suelos volcánicos ácidos de la región, combinados con la abundante lluvia y el notable contraste térmico entre el día y la noche característico de la montaña media, crean un entorno muy propicio. Los factores que restan (una temperatura ligeramente elevada y la estacionalidad de la lluvia) tienen un impacto menor y no afectan el resultado final.

11.2. Assam, India: idoneidad alta (86,8 %)



TeaSuitability

Evaluador de idoneidad geográfica para el cultivo de té de calidad (modelo entrenado con datos reales de GBIF, WorldClim y SoilGrids).

Probabilidad de idoneidad

86.8%

Banda de idoneidad

Alta

¿Por qué este resultado?




Ilustración 12. Evaluación de Assam, principal región tealera mundial.

Esta evaluación actúa como una prueba de validación externa. Assam, la mayor región productora de té del mundo, es reconocida correctamente por el sistema, a pesar de su clima monzónico que es muy diferente al de Costa Rica. Es especialmente interesante que la temperatura se mencione como un factor limitante, y aun así, el resultado sea alto: el modelo considera un conjunto de condiciones en lugar de enfocarse en un solo factor.

11.3. Guanacaste seco, Costa Rica: no apta (3,7 %)



TeaSuitability

Evaluador de idoneidad geográfica para el cultivo de té de calidad (modelo entrenado con datos reales de GBIF, WorldClim y SoilGrids).

Probabilidad de idoneidad

3.7%

Banda de idoneidad

No apta

¿Por qué este resultado?




Ilustración 13. Evaluación de la zona seca de Guanacaste.

El tercer caso ilustra la capacidad de discriminación del sistema. Aunque se encuentra en el mismo país que Turrialba, recibe una valoración completamente diferente. Las razones que proporciona el modelo son agrónomicamente válidas: temperatura excesiva (27,5 °C, por encima del óptimo), suelo con un pH insuficientemente ácido (6,8) y una estación seca severa, con apenas 30 mm de lluvia en el trimestre más seco.

La diferencia entre estos dos lugares dentro del mismo país es, desde una perspectiva comercial, el hallazgo más significativo de este trabajo: el sistema no emite juicios generales por país, sino que identifica áreas específicas dentro de un mismo territorio.

12. Evolución del modelo y decisiones metodológicas

El modelo que presentamos no es fruto de un diseño perfecto desde el principio, sino que ha evolucionado a través de cuatro iteraciones sucesivas. En cada una de ellas, las decisiones se tomaron basándose en la evidencia recopilada de la anterior. Documentar este proceso es, en mi opinión, tan importante como el resultado final, ya que revela los criterios utilizados y los riesgos identificados a lo largo del camino.

12.1. Primera iteración: solo variables climáticas

La versión inicial utilizó cuatro variables climáticas y topográficas básicas. Aunque el modelo funcionaba, tenía una clara limitación: no incluía información sobre el suelo. Esto es crucial,

ya que el pH es uno de los factores más importantes para el té, que requiere condiciones ácidas entre 4,5 y 5,6 (Hajiboland, 2017). Por lo tanto, un modelo de idoneidad para este cultivo sin considerar la variable edáfica resultaba incompleto desde una perspectiva agronómica.

12.2. Segunda iteración: incorporación del suelo

En esta fase, se añadió el pH del suelo utilizando datos de SoilGrids (Poggio et al., 2021). La dificultad previamente mencionada —la falta temporal de acceso al servicio de consulta— nos llevó a acceder directamente a los archivos cartográficos y a convertir las coordenadas al sistema de proyección Homolosine interrumpida que utiliza esta fuente. Una vez resuelto el acceso, se muestreó el pH para todo el conjunto, obteniendo una mediana de 5,5, que se encuentra justo en el rango óptimo para el cultivo.

Esta adición mejoró la coherencia agronómica del sistema: a partir de este momento, el modelo pudo considerar la acidez del suelo como un factor explicativo, algo que la propia interpretabilidad confirmaría más adelante.

12.3. Tercera iteración: revisión de las variables bioclimáticas

La revisión de la literatura reciente llevó a replantear las variables climáticas. Bania et al. (2025) identifican los factores más influyentes en la distribución mundial del té, como la precipitación del trimestre más cálido, la temperatura media del trimestre más seco, la isotermalidad y el pH del suelo. Con base en estos hallazgos, se decidió reemplazar las variables térmicas anuales que se usaron al principio por un conjunto que incluye el rango diurno, la isotermalidad y la precipitación del trimestre seco.

La elección de no adoptar completamente el conjunto de variables de este estudio fue intencionada. Las variables definidas para trimestres específicos (el más cálido, el más seco, el más húmedo) son especialmente útiles en climas con estaciones térmicas bien marcadas, pero pierden relevancia en climas ecuatoriales donde la temperatura se mantiene casi constante durante todo el año. Dado que el caso de estudio se encuentra en un clima tropical isohídrico, se optó por indicadores de régimen anual y de estacionalidad hídrica, que son más relevantes en este contexto.

12.4. Cuarta iteración: exclusión de la isotermalidad

La inclusión de la isotermalidad (que relaciona la variación térmica diaria con la anual) generó un resultado que parecía contradictorio. El modelo asignó a Turrialba una idoneidad del 17 %, clasificándola como no apta, a pesar de que todas sus demás condiciones estaban dentro del rango óptimo para el cultivo: temperatura media de 21,6 °C, precipitación anual de 2.955 mm, 367 mm en el trimestre más seco, elevación de 897 m y un pH de suelo de 5,5.

El análisis de interpretabilidad nos permitió identificar de dónde venía el problema. La isotermalidad tenía una contribución negativa de 0,269, casi tres veces más que cualquier otro factor, mientras que las demás variables estaban aportando de manera positiva. El valor real de Turrialba, que es 81,8, refleja un clima ecuatorial muy estable; sin embargo, el registro mundial de las áreas donde se cultiva té está dominado por regiones monzónicas y subtropicales en Asia, donde esta variable muestra valores mucho más bajos.

La conclusión metodológica fue que la isotermalidad funcionaba más como un indicador geográfico que como un factor agronómico: en lugar de sugerir que las condiciones no eran adecuadas para el cultivo, señalaba que la zona no se parecía a aquellas donde el té se cultiva con mayor frecuencia. Este es un caso de una variable con un alto poder discriminante, pero por una razón engañosa, un riesgo que se menciona en la literatura sobre modelos de distribución de especies (Elith & Leathwick, 2009).

Decidimos excluirla, priorizando la coherencia agronómica en lugar del rendimiento estadístico. El impacto de esta decisión fue inmediato y fácil de verificar: Turrialba pasó de un 17 % a un 89,5 % de idoneidad, y la acidez del suelo se convirtió en el principal factor explicativo, un resultado que se alinea perfectamente con los requerimientos para el cultivo. Las tres ubicaciones de contraste que evaluamos después confirmaron el comportamiento esperado del sistema.

12.5. Configuración final y síntesis del proceso

Iteración	Configuración	Evidencia obtenida y decisión adoptada
1. ^a	4 variables climáticas y topográficas	Ausencia de información edáfica: se incorpora el pH del suelo
2. ^a	Se añade el pH del suelo (SoilGrids)	Mejora la coherencia agronómica: se revisan las variables climáticas
3. ^a	8 variables, con isothermalidad	Resultado incoherente en el caso de estudio: se analiza su causa
4. ^a	7 variables, sin isothermalidad (final)	Resultados coherentes y explicables agronómicamente

Tabla 4. Evolución del modelo a lo largo de las cuatro iteraciones.

Este proceso pone de manifiesto un principio fundamental que se aplica a todo el trabajo: cuando se trata de un problema práctico, el criterio de validez no puede basarse únicamente en estadísticas. Una variable que parece separar eficazmente las clases en el conjunto de entrenamiento podría estar haciéndolo por razones que no tienen nada que ver con el fenómeno que queremos modelar. Solo al contrastar con el conocimiento del dominio podemos identificar esta situación.

13. Limitaciones del estudio

La honestidad acerca de las limitaciones es fundamental para un análisis riguroso. A continuación, se detallan las principales limitaciones identificadas:

- **Sesgo de muestreo en las presencias:** los registros de GBIF muestran dónde se ha observado y documentado la planta, pero no necesariamente indican dónde hay plantaciones comerciales. Además, las regiones con mayor actividad científica tienden a estar sobrerrepresentadas (Beck, Böller, Erhardt, & Schwanghart, 2019). Aunque la validación espacial que hemos adoptado ayuda a mitigar este efecto, no lo elimina por completo.
- **Naturaleza de las pseudo-ausencias:** los puntos que consideramos no aptos son más bien una suposición metodológica que una verificación de campo. Algunos de estos puntos podrían corresponder a áreas adecuadas donde, por razones económicas o históricas, simplemente no se cultiva té.
- **Resolución espacial:** las variables climáticas que utilizamos tienen una resolución de aproximadamente 9 km, lo que significa que promedian condiciones en terrenos montañosos donde el clima puede cambiar en distancias cortas. Para tomar decisiones a nivel de finca, sería ideal contar con información más local.
- **Alcance de las variables:** el modelo tiene en cuenta el clima, la topografía y la acidez del suelo, pero no incluye factores como la profundidad o el drenaje del suelo, la

disponibilidad de mano de obra, la infraestructura o la distancia a los mercados, todos ellos cruciales para una decisión de inversión real.

- **Correlación y no causalidad:** el modelo establece asociaciones entre las condiciones ambientales y la presencia de té; por lo tanto, sus resultados deben interpretarse como estimaciones de idoneidad, no como garantías agronómicas.

14. Conclusiones

Este trabajo presenta un sistema de evaluación de idoneidad agrícola que abarca todo el proceso y cumple con los objetivos establecidos. Aquí están las conclusiones más destacadas:

- Se puede crear un conjunto de datos propio y de tamaño significativo (1.363 ubicaciones) al integrar tres fuentes públicas independientes, sin necesidad de utilizar datasets preexistentes o datos sintéticos.
- La validación geográfica es esencial en este tipo de análisis. La discrepancia entre la evaluación convencional y la espacial muestra que una metodología estándar habría sobreestimado el rendimiento del sistema.
- El modelo se generaliza de manera efectiva. Con un área bajo la curva ROC de 0,95 en la validación espacial, puede diferenciar de manera confiable entre zonas aptas y no aptas en áreas que no formaron parte de su entrenamiento.
- Las decisiones del modelo son coherentes desde el punto de vista agronómico. Los factores que el sistema identifica como clave (acidez del suelo, disponibilidad de agua, régimen térmico) coinciden con lo que la literatura especializada describe, lo que sugiere que está acertando por las razones correctas.
- El sistema proporciona un valor decisional. Identifica de manera autónoma las regiones de montaña media de Costa Rica como las de mayor potencial, que coinciden con la actual zona cafetalera del país, y descarta correctamente las áreas secas y las costas bajas.
- La productivización transforma el análisis en una herramienta práctica. La aplicación web y el mapa de idoneidad permiten que el conocimiento generado sea accesible para personas sin formación técnica.

En respuesta a la pregunta de negocio que dio origen a este trabajo: **efectivamente, hay zonas en Costa Rica con condiciones ambientales favorables para cultivar té de calidad**, concentradas en la franja montañosa central del país, y Turrialba se encuentra entre ellas con una idoneidad estimada del 89,5 %.

15. Líneas futuras de trabajo

- Proyección bajo escenarios de cambio climático. Integrar las proyecciones climáticas CMIP6 disponibles en WorldClim nos ayudaría a anticipar cómo cambiará el mapa de idoneidad hacia 2050, un aspecto cada vez más importante para la planificación agrícola.
- Ampliación de las variables de suelo. Incluir factores como la profundidad, el drenaje, el contenido de materia orgánica y la textura enriquecería la caracterización del suelo, que actualmente se limita al pH.
- Validación de campo. Comparar las predicciones con ensayos agronómicos en las áreas indicadas permitiría ajustar el sistema con datos locales.
- Capa prescriptiva. Ampliar el sistema para que no solo evalúe, sino que también sugiera intervenciones específicas (como la corrección del pH, riego adicional o la implementación de sombra) y estime su impacto en la idoneidad.

- Detección por teledetección. Utilizar imágenes satelitales para identificar las plantaciones existentes nos permitiría ampliar y verificar el conjunto de datos, reduciendo el sesgo de muestreo.

16. Bibliografía y fuentes de datos

Se recopilan únicamente las fuentes que son relevantes para el área de estudio y la metodología utilizada. Las técnicas de aprendizaje automático que se han empleado, como los métodos de conjunto, las máquinas de vectores de soporte, el apilamiento y la interpretabilidad a través de los valores de Shapley, son parte del contenido del máster y no se citan de manera individual.

- Bania, J. K., Deka, J. R., Paul, A., Nath, A. J., Sileshi, G. W., & Das, A. K. (2025). Highly suitable areas for tea (*Camellia sinensis*) production will decline under future climate change scenarios. *Environmental and Sustainability Indicators*, Volumen: 26 · Páginas: 100720.
- Barbet-Massin, M., Jiguet, F., Albert, C. H., & Thuiller, W. (2012). Selecting pseudo-absences for species distribution models: How, where and how many? *Methods in Ecology and Evolution*, Volumen: 3 · Número: 2 · Páginas: 327-338.
- Beck, J., Böller, M., Erhardt, A., & Schwanghart, W. (2019). Spatial bias in the GBIF database and its effect on modeling species' geographic distributions. *Ecological Informatics*, Volumen: 19 · Páginas: 10-15.
- Elith, J., & Leathwick, J. R. (2009). Species distribution models: Ecological explanation and prediction across space and time. *Annual Review of Ecology, Evolution, and Systematics*, Volumen: 40 · Páginas: 677-697.
- Fick, S. E., & Hijmans, R. J. (2017). WorldClim 2: New 1-km spatial resolution climate surfaces for global land areas. *International Journal of Climatology*, Volumen: 37 · Número: 12 · Páginas: 4302-4315.
- Hajiboland, R. (2017). Environmental and nutritional requirements for tea cultivation. *Folia Horticulturae*, Volumen: 29 · Número: 2 · Páginas: 199-220.
- Jayasinghe, S. L., & Kumar, L. (2020). Modeling the climate suitability of tea [*Camellia sinensis* (L.) O. Kuntze] in Sri Lanka in response to current and future climate change scenarios. *Agricultural and Forest Meteorology*, Volumen: 272-273 · Páginas: 102-117.
- Poggio, L., De Sousa, L. M., Batjes, N. H., Heuvelink, G. B., Kempen, B., Ribeiro, E., & Rossiter, D. (2021). SoilGrids 2.0: Producing soil information for the globe with quantified spatial uncertainty. *SOIL*, Volumen: 7 · Número: 1 · Páginas: 217-240.
- Prat Kricun, S. D., Belingheri, L. D., & Kuzdra, H. (2020). Rendimiento y calidad organoléptica de nuevos cultivares de té (*Camellia sinensis*) en progenies biclonales en Argentina. *RECyT (Revista de Ciencia y Tecnología)*, Volumen: 22 · Número: 34 · Páginas: 24-28.
- Roberts, D. R., Bahn, V., Ciuti, S., Boyce, M. S., Elith, J., Guillera-Aroita, G., & otros, y. (2017). Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography*, Volumen: 40 · Número: 8 · Páginas: 913-929.
- Secretariat, G. (2025, Agosto 28). *Global Biodiversity Information Facility — Occurrence download: Camellia sinensis (L.) O. Kuntze*. Tratto da <https://www.gbif.org/>

17. Anexos: código y repositorio

El código completo del proyecto, que está organizado en los ocho módulos que se describen en la Tabla 1, está disponible en el siguiente repositorio, al que los tutores tienen acceso:

Repositorio: https://github.com/valsulliotti/TFM_TeaSuitability_Valeria_Sulliotti

En este repositorio, se encuentran los cuadernos de trabajo en formato Colab, así como su exportación a HTML, la aplicación web, el modelo entrenado y los conjuntos de datos generados. Cada cuaderno viene con comentarios explicativos y funciones que siguen el estándar numpydoc, y se puede ejecutar de manera reproducible siguiendo el orden de los módulos.

Contenido de los anexos:

- **Anexo A:** construcción del conjunto de datos y análisis exploratorio (módulos A.1 y A.2).
- **Anexo B:** modelización, validación espacial y modelo final (módulos B.1, B.2 y B.3).
- **Anexo C:** interpretabilidad y aplicación web (módulos C.1 y C.2).
- **Anexo D:** generación del mapa de idoneidad (módulo D).
- **Anexo E:** justificación metodológica y respaldo bibliográfico. Este documento complementario detalla, para cada decisión tomada (como la elección de fuentes de datos, la selección de variables, el diseño de la validación y la comparación con antecedentes en el campo), la evidencia bibliográfica que la respalda.