

Justificación metodológica y respaldo bibliográfico

TFM TeaSuitability · Valeria Sullioti

Documento de apoyo para la defensa. Recoge, para cada decisión metodológica del trabajo, la evidencia bibliográfica que la respalda. Está pensado como material de consulta ante preguntas del tribunal y como fuente de citas para reforzar la memoria.

1. Por qué estas fuentes de datos

1.1. GBIF como fuente de presencias

Decisión: obtener las coordenadas de presencia de *Camellia sinensis* desde GBIF en lugar de recopilarlas manualmente de la literatura.

Respaldo:

- GBIF es la fuente dominante de datos de ocurrencia en modelización de nichos climáticos. Aloja la mayor colección mundial de registros de presencia (unos 3.560 millones en noviembre de 2025), es gratuita y de acceso abierto, y agrega datos de museos, atlas nacionales, campañas de investigación y ciencia ciudadana. La mayoría de los estudios recientes de modelización de nichos se apoyan principal o exclusivamente en GBIF.
- El estudio de referencia sobre idoneidad global del té (Bania et al., 2025) emplea exactamente esta misma fuente, combinando registros de GBIF con coordenadas extraídas de literatura científica.
- Estudios de idoneidad de otros cultivos siguen el mismo procedimiento. Por ejemplo, el modelado de aptitud de trigo, soja y arroz en Asia Oriental compila los registros de ocurrencia desde GBIF y los cruza con las 19 variables bioclimáticas de WorldClim.

Limitación que debe reconocerse:

La literatura documenta ampliamente que GBIF presenta sesgo espacial de muestreo: la intensidad de registro es desigual entre regiones por diferencias de financiación y de políticas de compartición de datos. Beck et al. (2014) demostraron que la agrupación espacial de registros en GBIF degrada la calidad de los modelos y que, además, esa pérdida de calidad pasa desapercibida con las métricas de evaluación estándar.

Este hallazgo refuerza la decisión adoptada en este trabajo: precisamente porque las métricas convencionales no detectan el problema, se implementó una validación cruzada espacial, que sí lo hace visible.

1.2. WorldClim como fuente climática

Decisión: emplear las variables bioclimáticas de WorldClim 2.1 a 5 minutos de resolución.

Respaldo:

- Las 19 variables bioclimáticas de WorldClim constituyen el conjunto de capas ambientales más empleado en modelización de distribución de especies, por su alta resolución, cobertura global y disponibilidad tanto para escenarios históricos como futuros.
- Bradie y Leung confirman que las variables bioclimáticas de WorldClim son el conjunto más utilizado en este campo. Booth et al. revisaron la literatura sobre modelos de máxima entropía y encontraron que más del 76 % empleaba al menos una de ellas y el 55 % las usaba todas. Fourcade et al. revisaron 190 estudios sobre organismos terrestres: más del 87 % utilizaba al menos una variable bioclimática.
- Se trata de superficies climáticas que interpolan observaciones de estaciones meteorológicas con corrección por elevación y topografía, produciendo promedios de largo plazo en lugar de

eventos meteorológicos concretos, que es precisamente lo que requieren los modelos de nicho ecológico.

- La elección de WorldClim aporta además compatibilidad con el mayor cuerpo de investigación ecológica publicada y con las proyecciones CMIP6 disponibles bajo el mismo marco, lo que facilita la línea futura de trabajo sobre escenarios climáticos.

1.3. SoilGrids y la inclusión del suelo

Decisión: incorporar el pH del suelo procedente de SoilGrids, pese a la complejidad técnica añadida.

Respaldo:

- Bania et al. (2025) señalan explícitamente como carencia de los estudios previos sobre idoneidad del té que se han apoyado principalmente en variables bioclimáticas sin incorporar parámetros de suelo. Su trabajo incorpora datos edáficos precisamente para mejorar la precisión del modelo y su relevancia ecológica.
- En dicho estudio, el pH del suelo resulta ser la tercera variable más influyente en la distribución mundial del té, por detrás únicamente de la precipitación del trimestre más cálido y de la temperatura media del trimestre más seco.
- Un estudio reciente sobre plantaciones de té en Nanping (China) que combina teledetección y modelización identifica la acidez del suelo como determinante crítico para *Camellia sinensis*.
- El análisis comparativo de idoneidad del té y su principal plaga en China identifica como predictores ambientales compartidos la temperatura, la elevación y el pH del suelo, e incluye entre sus variables de respuesta el rango diurno medio (bio2).

Esta última referencia es especialmente pertinente: valida simultáneamente tres de las variables empleadas en este trabajo (temperatura, elevación y pH) y respalda el uso del rango diurno medio.

2. Por qué estas siete variables y no las diecinueve

2.1. El criterio de selección aplicado

La literatura identifica tres enfoques habituales para seleccionar variables en modelos de distribución de especies:

- Emplear todas las variables bioclimáticas disponibles sin justificación.
- Reducir el número de covariables para controlar la colinealidad.
- Seleccionar variables a partir del conocimiento ecológico, asumiendo una relación causal entre la variable climática y la ecofisiología, los rasgos de historia vital o los requerimientos de hábitat de la especie.

Este trabajo aplica el tercer enfoque, complementado con el segundo. Se trata del procedimiento recomendado frente al primero, que la literatura describe como el más común pero también el menos defendible.

Respaldo de la decisión de no usar todas las variables:

- En ausencia de conocimiento específico sobre qué variables determinan la distribución de una especie puede resultar tentador construir modelos con un gran número de predictores, pero esos modelos corren el riesgo de un desempeño pobre.
- Bania et al. (2025) parten de 51 variables y descartan 31 por colinealidad mediante análisis del factor de inflación de la varianza antes de modelar. Es decir, incluso el estudio más exhaustivo sobre el tema reduce su conjunto en más de un 60 %.

2.2. Justificación variable por variable

Variable	Justificación agronómica	Respaldo bibliográfico
Temperatura media anual (bio1)	El té crece en un rango óptimo de 18-25 °C; por debajo de 13 °C y por encima de 30 °C se reduce el crecimiento del brote	Hajiboland (2017); identificada como predictor compartido en el estudio sobre té y su plaga principal en China
Rango diurno medio (bio2)	La oscilación entre la máxima diurna y la mínima nocturna condiciona la respiración nocturna y la acumulación de compuestos de calidad	Incluida entre las seis variables más influyentes en Bania et al. (2025); analizada como variable de respuesta para el té en China
Precipitación anual (bio12)	Mínimo de 1.200 mm anuales; óptimo entre 2.500 y 3.000 mm. La deficiencia hídrica es el principal factor limitante de la producción	Hajiboland (2017); Bania et al. (2025) destacan las variables de precipitación como las de mayor contribución
Estacionalidad de precipitación (bio15)	La distribución de la lluvia a lo largo del año limita el rendimiento tanto o más que su volumen total	Hajiboland (2017) subraya que la distribución desigual limita el rendimiento anual pese a una lluvia total suficiente
Precipitación del trimestre seco (bio17)	Cuantifica el agua disponible en el período crítico; la sequía reduce el rendimiento entre un 14 % y un 20 %	Hajiboland (2017), que documenta además mortalidad de plantas del 6-19 % por sequía
Elevación	El cultivo se desarrolla desde el nivel del mar hasta unos 2.200 m; la altitud condiciona calidad y rendimiento	Hajiboland (2017); identificada como predictor compartido en el estudio sobre té en China
pH del suelo	Requerimiento más característico del cultivo: óptimo de 4,5 a 5,6. Por encima de 6,0 aparecen clorosis y albinismo	Hajiboland (2017); Bania et al. (2025), tercera variable más influyente; estudios sobre suelos de pH elevado en China

2.3. La exclusión de la isothermalidad

La isothermalidad (bio3) figura entre las variables más influyentes según Bania et al. (2025). Su exclusión en este trabajo se sustenta en dos argumentos:

- Argumento empírico. Su inclusión asignaba a Turrialba una idoneidad del 17 %, con una contribución negativa de 0,269 (casi el triple que cualquier otra variable), pese a que todas las demás condiciones se situaban en el rango óptimo del cultivo. El valor real de la zona (81,8) corresponde a un clima ecuatorial extremadamente estable, atípico respecto al registro mundial de té, dominado por regiones monzónicas y subtropicales.
- Argumento metodológico. La literatura advierte expresamente contra la complejidad de modelo sin justificación ecológica y recomienda seleccionar variables asumiendo una relación causal con la ecofisiología de la especie. Una variable que discrimina por similitud geográfica con la región de entrenamiento, y no por adecuación agronómica, no cumple ese criterio.

Formulación sugerida para la defensa: «Bania et al. identifican la isothermalidad entre las variables más influyentes a escala global, pero su estudio se realiza a escala planetaria y con un registro dominado por Asia monzónica. En un caso de estudio ecuatorial, comprobé empíricamente que esa variable penalizaba climas isohídricos por razones geográficas y no agronómicas, por lo que la excluí siguiendo el criterio de selección basada en conocimiento ecológico.»

3. Por qué esta metodología

3.1. Enfoque de solo presencias y pseudo-ausencias

Decisión: plantear el problema como clasificación binaria generando pseudo-ausencias, en lugar de asignar directamente categorías de idoneidad.

Respaldo:

- Es el planteamiento estándar en modelización de distribución de especies cuando solo se dispone de registros de presencia (Elith y Leathwick, 2009).
- Barbet-Massin et al. (2012) analizan específicamente cómo, dónde y cuántas pseudo-ausencias generar, y recomiendan para métodos de clasificación un número equivalente al de presencias y una distancia mínima de exclusión respecto a los puntos conocidos. Ambos criterios se han seguido en este trabajo.
- La alternativa —asignar directamente categorías de idoneidad alta, media o baja— carecería de respaldo empírico, ya que no existe un registro verificable de esos grados intermedios. Derivarlas de la probabilidad predicha resulta metodológicamente más defendible.

3.2. Validación cruzada espacial

Decisión: evaluar el modelo mediante bloques geográficos en lugar de una división aleatoria.

Respaldo:

- Roberts et al. (2017) establecen que, en datos con estructura espacial, la validación cruzada aleatoria produce estimaciones optimistas del rendimiento porque los conjuntos de entrenamiento y prueba no son independientes. Recomiendan esquemas de validación por bloques espaciales.
- Beck et al. (2014) demostraron que la pérdida de calidad derivada de la agrupación espacial de registros pasa desapercibida con las métricas de evaluación estándar, lo que refuerza la necesidad de una validación específicamente espacial.

Este punto constituye una diferencia relevante respecto a buena parte de los estudios previos sobre idoneidad del té, que reportan valores de AUC obtenidos mediante validación aleatoria. La comparación directa de cifras entre estudios debe hacerse, por tanto, con cautela.

3.3. Comparación de modelos y combinación por apilamiento

Decisión: comparar cuatro algoritmos y combinarlos, en lugar de emplear un único modelo.

Respaldo:

- Bania et al. (2025) señalan como limitación de los estudios previos sobre té que exploraron un único modelo para predecir la idoneidad del hábitat. Su trabajo emplea un conjunto de cinco modelos precisamente para superar esa limitación.
- Los antecedentes en el cultivo del té ilustran esa dependencia de un solo algoritmo: Bhagat et al. (2016) en Assam, Jayasinghe y Kumar (2020) en Sri Lanka, Kenia, India y China, Tibpromma et al. (2021) a escala global y Wang et al. (2024) en China emplean todos el modelo de máxima entropía como única técnica.

La comparación de cuatro algoritmos y su combinación posterior sitúa este trabajo en línea con la aproximación más reciente y exigente del campo, y no con la práctica dominante hasta 2024.

3.4. Sobre las cifras de rendimiento obtenidas

Los valores alcanzados en este trabajo resultan comparables a los publicados en la literatura del ámbito, aun habiéndose obtenido bajo un esquema de validación más exigente:

Estudio	Ámbito	Rendimiento reportado
Jayasinghe y Kumar (2020)	Sri Lanka (MaxEnt)	AUC medio de 0,92
Modelado de trigo, soja y arroz en Asia Oriental	Cultivos, MaxEnt	AUC entre 0,833 y 0,882
Este trabajo	Global, validación espacial	AUC espacial de 0,95

Conviene subrayar que las cifras no son estrictamente comparables, dado que los estudios citados emplean validación aleatoria. El valor obtenido aquí procede de predecir sobre bloques geográficos no vistos, un escenario más desfavorable.

4. Antecedentes en el estudio de la idoneidad del té

Situar el trabajo respecto a los estudios previos permite delimitar su aportación. Los antecedentes identificados son los siguientes:

Estudio	Ámbito geográfico	Enfoque	Incorpora suelo
Bhagat et al. (2016)	Assam, India	MaxEnt	No
Jayasinghe y Kumar (2020)	Sri Lanka, Kenia, India y China	MaxEnt	No
Tibpromma et al. (2021)	Global	MaxEnt	No
Wang et al. (2024)	China	MaxEnt	No
Bania et al. (2025)	Global	Conjunto de 5 modelos	Sí
Este trabajo	Global, con caso de estudio en Costa Rica	Comparación de 4 algoritmos y apilamiento	Sí

4.1. Aportación diferencial de este trabajo

- Incorpora parámetros de suelo, carencia que Bania et al. (2025) señalan expresamente en los estudios anteriores a 2025.
- Compara varios algoritmos en lugar de emplear uno solo, limitación igualmente señalada por dichos autores respecto a la literatura previa.
- Aplica validación cruzada espacial, mientras que los antecedentes reportan métricas obtenidas con validación aleatoria.
- Incorpora una capa de interpretabilidad que explica cada predicción individual, ausente en los trabajos revisados.
- Aborda un territorio no productor —Costa Rica—, mientras que los estudios previos se centran en países con producción establecida.
- Culmina en una herramienta operativa y no únicamente en un mapa de resultados.

5. Preguntas previsibles del tribunal y respuestas sugeridas

¿Por qué WorldClim y no otra fuente climática?

Porque sus variables bioclimáticas son el conjunto de capas ambientales más empleado en modelización de distribución de especies, con cobertura global, resolución adecuada y disponibilidad de proyecciones futuras bajo el mismo marco. Más del 87 % de los estudios revisados sobre organismos terrestres emplean al menos una de estas variables. Alternativas como ERA5 ofrecen mayor resolución temporal, pero están diseñadas para análisis meteorológico, no para modelado de nicho.

¿Por qué siete variables y no las diecinueve disponibles?

Porque incluir muchos predictores sin justificación ecológica degrada el desempeño del modelo e introduce colinealidad. Apliqué el criterio de selección basada en conocimiento ecológico: cada variable corresponde a un requerimiento documentado del cultivo. El estudio de referencia más reciente descarta 31 de sus 51 variables iniciales por este mismo motivo.

¿No es un problema el sesgo de muestreo de GBIF?

Sí, y está documentado en la literatura. Beck et al. demostraron que la agrupación espacial de registros degrada los modelos y que esa degradación no se detecta con métricas convencionales. Precisamente por eso implementé validación cruzada espacial, que sí revela el problema: la caída del F1 entre la evaluación clásica y la espacial es la medida de ese sesgo.

¿Por qué generar pseudo-ausencias en lugar de usar ausencias reales?

Porque no existe un registro verificable de lugares donde con certeza no se puede cultivar té. Es un problema clásico de solo presencias. Seguí las recomendaciones de Barbet-Massin et al. sobre número de pseudo-ausencias y distancia mínima de exclusión.

¿Por qué excluyó la isothermalidad si la literatura la destaca?

Por evidencia empírica. Su inclusión penalizaba a Turrialba con una contribución negativa casi tres veces superior a la de cualquier otra variable, pese a que las demás condiciones eran óptimas. El análisis mostró que actuaba como identificador geográfico y no como factor agronómico, penalizando climas ecuatoriales por no asemejarse a las regiones monzónicas donde se concentra el registro mundial.

¿Cómo sabe que su AUC de 0,95 es bueno?

Es comparable a los valores publicados en el campo —Jayasinghe y Kumar reportan 0,92 para Sri Lanka, y los modelos de cultivos en Asia Oriental entre 0,83 y 0,88—, con el matiz de que aquellos emplean validación aleatoria y el mío procede de predecir sobre bloques geográficos no vistos, un escenario más exigente.

¿Por qué combinar varios modelos en lugar de usar el mejor?

Porque la limitación señalada en la literatura previa sobre té es precisamente haber explorado un único modelo. El estudio de referencia de 2025 emplea un conjunto de cinco algoritmos por ese motivo. Además, el apilamiento aprovecha las fortalezas complementarias de cada técnica.

¿Qué aporta su trabajo respecto a Bania et al. (2025)?

Comparte enfoque y fuentes, lo que valida la metodología. Aporta tres elementos: validación cruzada espacial en lugar de aleatoria, una capa de interpretabilidad que explica cada predicción individual, y la productivización en una herramienta operativa. Además aplica el análisis a un territorio no productor, lo que constituye un caso de uso distinto: no evaluar dónde peligra el cultivo existente, sino dónde podría establecerse.

6. Fuentes consultadas para esta justificación

Se indican los enlaces para que puedan verificarse los datos bibliográficos completos antes de su incorporación definitiva a la memoria.

Sobre el cultivo del té y su idoneidad

- Bania, J. K. et al. (2025). Highly suitable areas for tea (*Camellia sinensis*) production will decline under future climate change scenarios. *Environmental and Sustainability Indicators*, 26, 100720. <https://www.sciencedirect.com/science/article/pii/S2665972725001412>
- Hajiboland, R. (2017). Environmental and nutritional requirements for tea cultivation. *Folia Horticulturae*, 29(2), 199-220.
- Jayasinghe, S. L. y Kumar, L. (2019/2020). Modeling the climate suitability of tea in Sri Lanka in response to current and future climate change scenarios. *Agricultural and Forest Meteorology*. <https://www.sciencedirect.com/science/article/abs/pii/S0168192319301388>
- Comparative analysis of habitat suitability for a crop and its primary insect herbivore (2024). *Frontiers in Ecology and Evolution*, 11. <https://www.frontiersin.org/journals/ecology-and-evolution/articles/10.3389/fevo.2023.1305369/full>
- MaxEnt with remote sensing for tea plantation suitability under climate change. <https://pmc.ncbi.nlm.nih.gov/articles/PMC13231076/>
- Analysis of growth resistance mechanisms in tea plants in high-pH regions of Northern China. <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC10011619/>

Sobre WorldClim y la selección de variables

- Fick, S. E. y Hijmans, R. J. (2017). WorldClim 2: New 1-km spatial resolution climate surfaces for global land areas. *International Journal of Climatology*, 37(12), 4302-4315.
- Title, P. O. y Bemmels, J. B. ENVIREM: An expanded set of bioclimatic and topographic variables. <https://www.biorxiv.org/content/10.1101/075200v1.full>
- Improving the Use of Species Distribution Models in Conservation Planning and Management under Climate Change. <https://pmc.ncbi.nlm.nih.gov/articles/PMC4242662/>
- Blessing and curse of bioclimatic variables: A comparison of different calculation schemes and datasets for species distribution modeling. <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC10534195/>

Sobre GBIF, sesgo de muestreo y validación

- Beck, J., Böller, M., Erhardt, A. y Schwanghart, W. (2014). Spatial bias in the GBIF database and its effect on modeling species geographic distributions. *Ecological Informatics*, 19, 10-15.
- Roberts, D. R. et al. (2017). Cross-validation strategies for data with temporal, spatial, hierarchical, or phylogenetic structure. *Ecography*, 40(8), 913-929.
- Barbet-Massin, M., Jiguet, F., Albert, C. H. y Thuiller, W. (2012). Selecting pseudo-absences for species distribution models. *Methods in Ecology and Evolution*, 3(2), 327-338.
- MaxEnt model strategies to studying current and future potential land suitability dynamics of wheat, soybean and rice in East Asia. <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC10735186/>

Sobre SoilGrids

- Poggio, L. et al. (2021). SoilGrids 2.0: Producing soil information for the globe with quantified spatial uncertainty. *SOIL*, 7(1), 217-240.

Nota: los estudios de Bhagat et al. (2016), Tibpromma et al. (2021) y Wang et al. (2024) se citan a través de la revisión de antecedentes de Bania et al. (2025). Si se desea citarlos directamente en la memoria, conviene localizar y verificar sus referencias completas.